

XGBoost.

Ensamble $\left\{ \begin{array}{l} \text{Combinación} \\ \text{de varios modelos} \end{array} \right.$
xgboost \rightarrow Árboles.

Extreme Gradient Boosting

utilizamos los datos de train con
múltiples funciones (x_i) para
predecir salida (y_i).

Supervisada \rightarrow Conocida la
salida

No supervisada \rightarrow No conocemos
salida.

Función OBJETIVO: Pérdida (training loss) + Regularización Ω .


$$\underline{\text{obj}(\theta)} = \underline{L(\theta)} + \underline{\Omega(\theta)}.$$

L : Mide qué tan predictivo es el modelo respecto al train.


$$L(\theta) = \sum_i (y_i - \hat{y}_i)^2$$

pérdida de la regresión logística.

$$\underline{L(\theta)} = \sum_i [y_i \ln(1 + e^{-\hat{y}_i}) + (1 - y_i) \ln(1 + e^{\hat{y}_i})] \quad \underline{\Omega} \rightarrow \text{optimizar.}$$




Ω : Controla la complejidad del Modelo (evitar sobreajuste).



Over fitting.

Alta complejidad.

muchos splits. $\Omega \uparrow$





pocos splits $\Omega \downarrow$



$L(\theta) \uparrow$

Xgboost \rightarrow conjunto de árboles de decisión

input: Edad, Genero, Ocupación, etc.



jugar videojuegos



complemento.

$$f(\text{cara triste}) = -1 - 0.9 = -1.9$$

$$f(\text{cara feliz}) = +2 + 0.9 = \underline{\underline{2.9}}$$

Cómo traducirlo al modelo:

$$\underline{\hat{y}}_i = \sum_{k=1}^K f_k(x_i), \quad f_k \in \underline{F}$$

posibles para tu modelo y tus datos.

K : Número de árboles

f_k : función en el espacio funcional F

F : conjunto de todos los CART Posibles.

función OBJETIVO:

$$\text{obj}(\theta) = \mathcal{L}(\theta) + \mathcal{Q}(\theta).$$

$$= \sum_{i=1}^n \underset{\substack{\uparrow \\ \text{Loss}}}{\ell(y_i, \hat{y}_i)} + \sum_{k=1}^K \underset{\substack{\uparrow \\ \text{Regularización.}}}{w(f_k)}.$$

$w(f_k) \rightarrow$ complejidad del modelo.
del árbol f_k .

Boosting Tree: (función objetivo de forma recurrente).

$$\text{obj} = \sum_{i=1}^n \ell(y_i, \hat{y}_i^{(t)}) + \sum_{i=1}^t w(f_i).$$

$w(f_t) + \text{Const.}$

Predicción para cada paso t :

\hat{y}_i : predicción.

$$\hat{y}_i^{(0)} = 0$$

$$\hat{y}_i^{(1)} = f_1(x_i) = \hat{y}_i^{(0)} + f_1(x_i)$$

$$\hat{y}_i^{(2)} = f_1(x_i) + f_2(x_i) = \hat{y}_i^{(1)} + f_2(x_i)$$

$$\boxed{\hat{y}_i^{(t)}} = \sum_{k=1}^t f_k(x_i) = \boxed{\hat{y}_i^{(t-1)} + f_t(x_i)}.$$

La función objetivo:

$$\text{obj}^{(t)} = \sum_{i=1}^n \underset{\substack{\downarrow \\ \text{MSE}}}{\ell(y_i, \hat{y}_i^{(t-1)} + f_t(x_i))} + w(f_t) + \text{cte}$$

Función obj. Para MSE (Error cuadrático Medio).

$$\begin{aligned} \text{obj}^{(t)} &= \sum_{i=1}^n \left(y_i - \left(\hat{y}_i^{(t-1)} + f_t(x_i) \right) \right)^2 + w(f_t) + \text{conste.} \\ &= \sum_{i=1}^n \left[2(\hat{y}_i^{(t-1)} - y_i) f_t(x_i) + f_t(x_i)^2 \right] + w(f_t) + \text{conste.} \end{aligned}$$